




INFORMES DE PRÁCTICAS CON APACHE PIG ENTORNO CLOUDERA VM

IVANA SÁNCHEZ PÉREZ



INGENIERÍA
DE DATOS

Tarea 2: Procesamiento de Grandes Volúmenes de Datos y Lógica de Negocio

Introducción

Esta tarea escala el nivel de complejidad al trabajar con conjuntos de datos externos y scripts de automatización. Utilizando archivos en formato CSV de gran tamaño (opiniones y catálogos de libros), se pone a prueba la capacidad de Pig Latin para gestionar datos con esquemas complejos.

En este bloque, el enfoque principal es la transformación avanzada de datos, aplicando técnicas de:


- **Tipado y Casting:** Conversión de cadenas de texto en valores numéricos para cálculos matemáticos.
- **Agregación de Valor:** Implementación de funciones de promedio (AVG) y suma (SUM) para extraer indicadores clave.
- **Generación de Rankings:** Uso de lógica de ordenación y limitación para transformar miles de registros en informes ejecutivos de alto valor (como el Top 5 de valoraciones o el Top 10 de productividad por páginas).

PASOS

Paso 1: Preparación de los archivos en HDFS

En la terminal de Cloudera, fuera de Pig crearemos una carpeta para organizar los archivos que se hemos guardado en la carpeta compartida entre la máquina real y la virtual (cloudera)

hadoop fs -mkdir -p /user/cloudera/ejercicio2


A screenshot of a terminal window with a blue title bar. The title bar text is 'cloudera@quickstart:~'. Below the title bar is a menu bar with 'File', 'Edit', 'View', 'Search', 'Terminal', and 'Help'. The terminal shows two lines of text: '[cloudera@quickstart ~]\$ hadoop fs -mkdir -p /user/cloudera/ejercicio2' and '[cloudera@quickstart ~]\$' followed by a cursor. The terminal has a light gray background and a black border.

```
cloudera@quickstart:~  
File Edit View Search Terminal Help  
[cloudera@quickstart ~]$ hadoop fs -mkdir -p /user/cloudera/ejercicio2  
[cloudera@quickstart ~]$
```

Posteriormente subiremos los archivos que necesitaremos para realizar la actividad desde la carpeta compartida a una carpeta que crearemos en Cloudera:

```
hadoop fs put /media/sf_datos/Eopinions.csv /user/cloudera/ejercicio2/
```

```
hadoop fs -put /media/sf_datos/books.csv /user/cloudera/ejercicio2/
```




```
cloudera@quickstart:~  
File Edit View Search Terminal Help  
[cloudera@quickstart ~]$ hadoop fs -mkdir -p /user/cloudera/ejercicio2  
[cloudera@quickstart ~]$ hadoop fs -put /media/sf_datos/Eopinions.csv /user/cloudera/ejercicio2/  
[cloudera@quickstart ~]$ hadoop fs -put /media/sf_datos/books.csv /user/cloudera/ejercicio2/  
[cloudera@quickstart ~]$
```

Paso 2: Ejecutar el script de opiniones

Como ya tenemos el archivo proceso_opiniones.pig en nuestra carpeta compartida, lo ejecutaremos directamente sin entrar en la consola interactiva grunt:

```
pig /media/sf_datos/proceso_opiniones.pig
```



```
cloudera@quickstart:~  
File Edit View Search Terminal Help  
[cloudera@quickstart ~]$ pig /media/sf_datos/proceso_opiniones.pig  
log4j:WARN No appenders could be found for logger (org.apache.hadoop.util.Shell).  
log4j:WARN Please initialize the log4j system properly.  
log4j:WARN See http://logging.apache.org/log4j/1.2/faq.html#noconfig for more info.  
2026-04-30 10:46:31,354 [main] INFO org.apache.pig.Main - Apache Pig version 0.12.0-cdh5.13.0 (reexported) compiled Oct 17, 11:09:03  
2026-04-30 10:46:31,355 [main] INFO org.apache.pig.Main - Logging error messages to: /home/cloudera/pig_1777571191330.  
2026-04-30 10:46:33,046 [main] INFO org.apache.pig.impl.util.Utils - Default bootup file /home/cloudera/.pigbootup not  
2026-04-30 10:46:33,222 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - mapred.job.tracker is deprecated, use mapreduce.jobtracker.address  
2026-04-30 10:46:33,222 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - fs.default.name is deprecated, use fs.defaultFS  
2026-04-30 10:46:33,222 [main] INFO org.apache.pig.backend.hadoop.executionengine.HExecutionEngine - Connecting to hadle system at: hdfs://quickstart.cloudera:8020  
2026-04-30 10:46:33,936 [main] INFO org.apache.pig.backend.hadoop.executionengine.HExecutionEngine - Connecting to map e job tracker at: localhost:8021  
2026-04-30 10:46:33,999 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - fs.default.name is deprecated, use fs.defaultFS
```

Me da error, pues el script busca una ruta fija, así que se la vamos a dar.

Creamos la carpeta exacta que busca el script

```
hadoop fs -mkdir -p /user/cloudera/pig
```

Copiamos el archivo Eopinions.csv desde la carpeta compartida a esa ruta

```
hadoop fs -put /media/sf_datos/Eopinions.csv /user/cloudera/pig/
```

Y por si acaso, subimos de nuevo el de books a nuestra carpeta de trabajo

```
hadoop fs -mkdir -p /user/cloudera/ejercicio2
```

```
hadoop fs -put /media/sf_datos/books.csv /user/cloudera/ejercicio2/
```

```

cloudera@quickstart:~
File Edit View Search Terminal Help

[cloudera@quickstart ~]$ hadoop fs -mkdir /user/cloudera/pig
[cloudera@quickstart ~]$ hadoop fs -put /media/sf_datos/Eopinions.csv /user/cloudera/pig/
[cloudera@quickstart ~]$ hadoop fs -put /media/sf_datos/Eopinions.csv /user/cloudera/ejercicio2/
put: /user/cloudera/ejercicio2/Eopinions.csv: File exists
[cloudera@quickstart ~]$ pig /media/sf_datos/proceso_opiniones.pig
log4j:WARN No appenders could be found for logger (org.apache.hadoop.util.Shell).
log4j:WARN Please initialize the log4j system properly.
log4j:WARN See http://logging.apache.org/log4j/1.2/faq.html#noconfig for more info.
2026-04-30 10:52:15,587 [main] INFO org.apache.pig.Main - Apache Pig version 0.12.0-cdh5.13.0 (rexpoted) compiled Oct
17, 11:09:03
2026-04-30 10:52:15,587 [main] INFO org.apache.pig.Main - Logging error messages to: /home/cloudera/pig_1777571535569.
2026-04-30 10:52:17,257 [main] INFO org.apache.pig.impl.util.Util - Default bootup file /home/cloudera/.pigbootup not
2026-04-30 10:52:17,463 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - mapred.job.tracker is deprecate
tead, use mapreduce.jobtracker.address
2026-04-30 10:52:17,463 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - fs.default.name is deprecated.
d, use fs.defaultFS
2026-04-30 10:52:17,463 [main] INFO org.apache.pig.backend.hadoop.executionengine.HExecutionEngine - Connecting to had
le system at: hdfs://quickstart.cloudera:8020
2026-04-30 10:52:18,115 [main] INFO org.apache.pig.backend.hadoop.executionengine.HExecutionEngine - Connecting to map
e job tracker at: localhost:8021
2026-04-30 10:52:18,172 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - fs.default.name is deprecated.
d, use fs.defaultFS
2026-04-30 10:52:18,175 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - mapred.job.tracker is deprecate

```

```

Browse and run installed applications
cloudera@quickstart:~
File Edit View Search Terminal Help

Job Stats (time in seconds):
JobId Maps Reduces MaxMapTime MinMapTime AvgMapTime MedianMapTime MaxReduceTime MinReduceTime
duceTime MedianReduceTime Alias Feature Outputs
job_1777567184197_0009 1 1 10 10 10 8 8 8 8 csv_data,word_c
wordfile_flat,wordfile_grpd GROUP_BY,COMBINER
job_1777567184197_0010 1 1 5 5 5 6 6 6 6 word_count_des
ER
job_1777567184197_0011 1 1 6 6 6 7 7 7 7 word_count_des
_BY /user/cloudera/pig/out,

Input(s):
Successfully read 601 records (1691287 bytes) from: "/user/cloudera/pig/Eopinions.csv"

Output(s):
Successfully stored 15753 records (154866 bytes) in: "/user/cloudera/pig/out"

Counters:
Total records written : 15753
Total bytes written : 154866
Spillable Memory Manager spill count : 0
Total bags proactively spilled: 0
Total records proactively spilled: 0

Job DAG:
job_1777567184197_0009 -> job_1777567184197_0010,
job_1777567184197_0010 -> job_1777567184197_0011,
job_1777567184197_0011

2026-04-30 10:54:30,340 [main] INFO org.apache.hadoop.ipc.Client - Retrying connect to server: quickstart.cloudera/127
:52673. Already tried 0 time(s); retry policy is RetryUpToMaximumCountWithFixedSleep(maxRetries=3, sleepTime=1000 MILLI
S)
2026-04-30 10:54:31,372 [main] INFO org.apache.hadoop.ipc.Client - Retrying connect to server: quickstart.cloudera/127
:52673. Already tried 1 time(s); retry policy is RetryUpToMaximumCountWithFixedSleep(maxRetries=3, sleepTime=1000 MILLI
S)
2026-04-30 10:54:32,374 [main] INFO org.apache.hadoop.ipc.Client - Retrying connect to server: quickstart.cloudera/127
:52673. Already tried 2 time(s); retry policy is RetryUpToMaximumCountWithFixedSleep(maxRetries=3, sleepTime=1000 MILLI
S)

```

Paso 3: Script para los 5 escritores mejor valorados

Entramos en Pig escribiendo pig. Una vez dentro de grunt ejecutamos los siguientes comandos:

1. Cargamos los datos de libros

```
libros = LOAD '/user/cloudera/ejercicio2/books.csv' USING PigStorage(',') AS (id:int, titulo:chararray, autor:chararray, rating:float, isbn:chararray, isbn13:chararray, lang:chararray, paginas:int);
```

2. Agrupamos por autor para consolidar sus obras

```
por_autor = GROUP libros BY autor;
```

3. Calculamos la valoración media de cada escritor


```
ranking_val = FOREACH por_autor GENERATE group AS autor, AVG(libros.rating) AS media_rating;
```

4. Ordenamos y limitamos a 5

```
top5_val = LIMIT (ORDER ranking_val BY media_rating DESC) 5;
```

5. Guardamos

```
STORE top5_val INTO '/user/cloudera/ejercicio2/ranking_top5_valorados' USING PigStorage(',');
```



```
cloudera@quickstart:~  
File Edit View Search Terminal Help  
grunt> libros = LOAD '/user/cloudera/ejercicio2/books.csv' USING PigStorage(',') AS (id:int, titulo:chararray, autor:chararray, rating:float, isbn:chararray, isbn13:chararray, lang:chararray, paginas:int);  
grunt> por_autor = GROUP libros BY autor;  
ranking_val = FOREACH por_autor GENERATE group AS autor, AVG(libros.rating) AS media_rating;  
grunt> top5_val = LIMIT (ORDER ranking_val BY media_rating DESC) 5;  
grunt> fs -rm -r /user/cloudera/ejercicio2/ranking_top5_valorados  
STORE top5_val INTO '/user/cloudera/ejercicio2/ranking_top5_valorados' USING PigStorage(',');  
2026-04-30 11:41:32,239 [main] INFO org.apache.pig.tools.pigstats.ScriptState - Pig features used in the script: GROUP_BY,ORDER_BY,LIMIT  
2026-04-30 11:41:32,350 [main] INFO org.apache.pig.newplan.logical.optimizer.LogicalPlanOptimizer - {RULES_ENABLED=[AddForEach, ColumnMapKeyPrune, DuplicateForEachColumnRewrite, GroupByConstParallelSetter, ImplicitSplitInserter, LimitOptimizer, LoadTypeCastInserter, MergeFilter, MergeForEach, NewPartitionFilterOptimizer, PushDownForEachFlatten, PushUpFilter, SplitFilter, StreamTypeCastInserter], RULES_DISABLED=[FilterLogicExpressionSimplifier, PartitionFilterOptimizer]}  
2026-04-30 11:41:32,381 [main] INFO org.apache.hadoop.conf.Configuration.deprecation - mapred.textoutputformat.separator is deprecated. Instead, use mapreduce.output.textoutputformat.separator  
2026-04-30 11:41:32,478 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MRCompiler - File concatenation threshold: 100 optimistic? false
```

```

cloudera@quickstart:~
File Edit View Search Terminal Help
mplete
2026-04-30 11:44:12,250 [main] INFO org.apache.pig.tools.pigstats.SimplePigStats - Script Statistics:

HadoopVersion PigVersion UserId StartedAt FinishedAt Features
2.6.0-cdh5.13.0 0.12.0-cdh5.13.0 cloudera 2026-04-30 11:41:33 2026-04-30 11:44:12 GROUP_BY,ORDER_BY,LIM
IT

Success!

Job Stats (time in seconds):
JobId Maps Reduces MaxMapTime MinMapTime AvgMapTime MedianMapTime MaxReduceTime MinReduceTime AvgRe
duceTime MedianReduceTime Alias Feature Outputs
job_1777567184197_0028 1 1 9 9 9 7 7 7 7 libros,por_autor,rank
ing_val GROUP_BY,COMBINER
job_1777567184197_0029 1 1 4 4 4 7 7 7 7 1-15 SAMPLER
job_1777567184197_0030 1 1 5 5 5 5 5 5 5 1-15 ORDER_BY,COMB
INER
job_1777567184197_0031 1 1 4 4 4 5 5 5 5 1-15 /user
/cloudera/ejercicio2/ranking_top5_valorados,

Input(s):
Successfully read 11128 records (1551125 bytes) from: "/user/cloudera/ejercicio2/books.csv"

Output(s):
Successfully stored 5 records (166 bytes) in: "/user/cloudera/ejercicio2/ranking_top5_valorados"

Counters:
Total records written : 5
Total bytes written : 166
Spillable Memory Manager spill count : 0
Total bags proactively spilled: 0
Total records proactively spilled: 0

Job DAG:
job_1777567184197_0028 -> job_1777567184197_0029,
job_1777567184197_0029 -> job_1777567184197_0030,
job_1777567184197_0030 -> job_1777567184197_0031,
job_1777567184197_0031

```

Paso 4: Script para los 10 escritores con más páginas

1. Calculamos la suma de la columna páginas (\$7)

*ranking_pag = FOREACH por_autor GENERATE group AS autor,
SUM(libros.páginas) AS total_páginas;*

2. Ordenamos por volumen de páginas

top10_pag = LIMIT (ORDER ranking_pag BY total_páginas DESC) 10;

3. Guardamos

*STORE top10_pag INTO '/user/cloudera/ejercicio2/ranking_top10_páginas'
USING PigStorage(';');*

```

cloudera@quickstart:~
File Edit View Search Terminal Help

grunt> ranking_pag = FOREACH por_autor GENERATE group AS autor, SUM(libros.páginas) AS total_páginas;
grunt> top10_pag = LIMIT (ORDER ranking_pag BY total_páginas DESC) 10;
grunt> fs -rm -r /user/cloudera/ejercicio2/ranking_top10_páginas
Deleted /user/cloudera/ejercicio2/ranking_top10_páginas
grunt>
grunt> STORE top10_pag INTO '/user/cloudera/ejercicio2/ranking_top10_páginas' USING PigStorage(';');

2026-04-30 11:45:59,105 [main] INFO org.apache.pig.tools.pigstats.ScriptState - Pig Features used in the script: GROUP_BY,OR
DER_BY,LIMIT
2026-04-30 11:45:59,107 [main] INFO org.apache.pig.newplan.logical.optimizer.LogicalPlanOptimizer - {RULES_ENABLED=[AddForEa
ch, ColumnMapKeyPrune, DuplicateForEachColumnRewrite, GroupByConstParallelSetter, ImplicitSplitInserter, LimitOptimizer, Load
TypeCastInserter, MergeFilter, MergeForEach, NewPartitionFilterOptimizer, PushDownForEachFlatten, PushUpFilter, SplitFilter,
StreamTypeCastInserter], RULES_DISABLED=[FilterLogicExpressionSimplifier, PartitionFilterOptimizer]}
2026-04-30 11:45:59,125 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MRCompiler - File concatena
tion threshold: 100 optimistic? false
2026-04-30 11:45:59,143 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.CombinerOptimizer - Choosin
g to move algebraic foreach to combiner
2026-04-30 11:45:59,154 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MultiQueryOptimizer - MR pl
an size before optimization: 4
2026-04-30 11:45:59,154 [main] INFO org.apache.pig.backend.hadoop.executionengine.mapReduceLayer.MultiQueryOptimizer - MR pl
an size after optimization: 4

```



```

cloudera@quickstart:~
File Edit View Search Terminal Help

HadoopVersion  PigVersion  UserId  StartedAt  FinishedAt  Features
2.6.0-cdh5.13.0 0.12.0-cdh5.13.0  cloudera  2026-04-30 11:45:59  2026-04-30 11:48:46  GROUP_BY,ORDER_BY,LIM
IT

Success!

Job Stats (time in seconds):
JobId  Maps  Reduces  MaxMapTime  MinMapTime  AvgMapTime  MedianMapTime  MaxReduceTime  MinReduceTime  AvgRe
duceTime  MedianReduceTime  Alias  Feature  Outputs
job_1777567184197_0032  1  1  7  7  7  9  9  9  9  libros,por_autor,rank
ing_pag GROUP_BY,COMBINER
job_1777567184197_0033  1  1  4  4  4  6  6  6  6  1-55  SAMPLER
job_1777567184197_0034  1  1  6  6  6  5  5  5  5  1-55  ORDER_BY,COMB
INER
job_1777567184197_0035  1  1  6  6  6  5  5  5  5  1-55  /user
/cloudera/ejercicio2/ranking_top10_paginas,

Input(s):
Successfully read 11128 records (1551125 bytes) from: "/user/cloudera/ejercicio2/books.csv"

Output(s):
Successfully stored 10 records (211 bytes) in: "/user/cloudera/ejercicio2/ranking_top10_paginas"

Counters:
Total records written : 10
Total bytes written : 211
Spillable Memory Manager spill count : 0
Total bags proactively spilled: 0
Total records proactively spilled: 0

Job DAG:
job_1777567184197_0032 -> job_1777567184197_0033,
job_1777567184197_0033 -> job_1777567184197_0034,
job_1777567184197_0034 -> job_1777567184197_0035,
job_1777567184197_0035

```

Paso 5: Ver los resultados

Para comprobar que todo está bien, salimos de Pig con quit y miramos los archivos generados:

- 1- Ver ranking de valoración

```
hadoop fs -cat /user/cloudera/ejercicio2/top5_escritores/part-r-00000
```

- 2- Ver ranking de páginas

```
hadoop fs -cat /user/cloudera/ejercicio2/top10_paginas/part-r-00000
```

```

cloudera@quickstart:~
File Edit View Search Terminal Help

[cloudera@quickstart ~]$ hadoop fs -cat /user/cloudera/ejercicio2/ranking_top5_valorados/part-r-00000
John Diamond,5.0
Julie Sylvester/David Sylvester,5.0
Chris Green/Chris Wright/Paul Douglas Gardner,5.0
Middlesex Borough Heritage Committee,5.0
Keith Donohue,5.0
[cloudera@quickstart ~]$ hadoop fs -cat /user/cloudera/ejercicio2/ranking_top10_paginas/part-r-00000
Stephen King,18219
Orson Scott Card,14066
J.R.R. Tolkien,12537
Dan Simmons,11700
P.G. Wodehouse,11619
Mercedes Lackey,11480
Piers Anthony,10883
Agatha Christie,10556
Laurell K. Hamilton,10219
Sandra Brown,10091
[cloudera@quickstart ~]$

```

Análisis de los resultados finales

1. Top 5 Escritores mejor valorados:

- Vemos nombres como John Diamond o Keith Donohue con una puntuación media de 5.0.
- Este ranking muestra a los autores que tienen la nota máxima en sus libros.

2. Top 10 Escritores con más páginas:

- Aquí los resultados son impresionantes y lógicos: Stephen King lidera con 18.219 páginas, seguido de Orson Scott Card con 14.066 y J.R.R. Tolkien con 12.537.
- Se han conseguido sumar correctamente las páginas de todos los libros de cada autor.

Descargo los dos resultados a la carpeta compartida para tenerlos en mi PC

```
hadoop fs -get /user/cloudera/ejercicio2/ranking_top5_valorados/part-r-000000 /media/sf_datos/resultado_valorados.csv
```

```
hadoop fs -get /user/cloudera/ejercicio2/ranking_top10_paginas/part-r-000000 /media/sf_datos/resultado_paginas.csv
```



Conclusiones

En esta tarea, hemos pasado de realizar operaciones básicas a convertirnos en un gestor de flujos de datos. Mientras que en la primera tarea aprendimos los comandos, en esta hemos aprendido la lógica de procesamiento profesional:

1. Automatización mediante Scripts (.pig)

- Hemos aprendido que para procesos repetitivos no se usa la consola interactiva, sino archivos de guion (.pig).
- **Conclusión:** Un ingeniero de datos programa procesos que pueden ejecutarse de forma masiva y automática sin intervención humana constante.

2. Tipado y Casting de Datos

- Hemos descubierto que los datos crudos en un CSV son "mudos" (solo texto).
- Hemos aprendido a realizar un Casting (conversión): transformar texto en float para promedios de valoración y en int para sumas de páginas.
- Conclusión: La integridad de los tipos de datos es la base de un análisis preciso; sin el tipo correcto, el cálculo matemático es imposible.

3. Técnicas de Agregación de Valor

- Hemos pasado de contar filas a extraer conocimiento real mediante funciones como AVG (calidad) y SUM (volumen).
- Conclusión: El valor del Big Data no está en el dato individual, sino en la capacidad de resumir miles de registros en un solo indicador clave para el negocio.

4. Selección por Índice y Limpieza de Esquemas

- Hemos aprendido a usar identificadores posicionales (\$0, \$1, \$2...) cuando las cabeceras de los archivos fallan o son confusas.
- Conclusión: Un buen procesador de datos debe ser flexible y saber navegar por archivos "sucios" o mal formateados para extraer la información correcta.

5. Lógica de Ranking (Ordenar y Limitar)

- Hemos dominado la combinación de ORDER ... DESC y LIMIT para generar informes de alto nivel (los 5 mejores, los 10 más grandes).
- Conclusión: En entornos de millones de datos, la capacidad de filtrar y mostrar solo lo más relevante es lo que permite tomar decisiones empresariales rápidas.