

Gestión de Workflows con Apache Oozie



Ivana Sánchez Pérez



Informe de Prácticas: Gestión de Workflows con Apache Oozie


1. Introducción y Preparación del Entorno

En esta práctica se ha trabajado con Apache Oozie, el motor de orquestación de flujos de trabajo para el ecosistema Hadoop. El objetivo principal ha sido configurar, personalizar y ejecutar un workflow de MapReduce dentro del entorno Cloudera VM.

Como paso inicial, se localizaron los ejemplos preinstalados en el sistema y se trasladaron al área de trabajo personal para su manipulación:


- **Copia de recursos:** Se extrajo el archivo comprimido desde la ruta de documentación de Oozie al directorio workspace.


```
cp /usr/share/doc/oozie-4.1.0+cdh5.13.0+458/oozie-examples.tar.gz  
/home/cloudera/workspace/
```



- **Descompresión y comprobación del contenido:** Se procedió a descomprimir los ejemplos para acceder a las estructuras de configuración.

```
tar -xvzf oozie-examples.tar.gz
```





```

cloudera@quickstart:~
File Edit View Search Terminal Help
[cloudera@quickstart ~]$ ls -l /home/cloudera/workspace/examples/
total 12
drwxr-xr-x 26 cloudera cloudera 4096 Oct  4 2017 apps
drwxrwxr-x  4 cloudera cloudera 4096 May  1 13:47 input-data
drwxr-xr-x  3 cloudera cloudera 4096 Oct  4 2017 src
[cloudera@quickstart ~]$

```

2. Personalización del Workflow y Carga en HDFS

Para cumplir con los requisitos de la tarea, se realizó una personalización profunda de los archivos de configuración antes de su despliegue en el sistema de archivos distribuido (HDFS).

Modificación del archivo workflow.xml

Se editó el archivo de lógica del flujo para asignar nombres identificativos únicos:

- Nombre del Workflow: Se actualizó a workflow_lvanaSanchez.
- Nombre de la Acción: El nodo de ejecución se renombró como action_lvanaSanchez.
- Nodos de Control: Se ajustó el nodo <start to="..."> para que apuntara correctamente a la nueva acción definida.

```
cloudera@quickstart:~/workspace
File Edit View Search Terminal Help
GNU nano 2.0.9 File: ...udera/workspace/examples/apps/map-reduce/workflow.xml

! --
Licensed to the Apache Software Foundation (ASF) under one
or more contributor license agreements. See the NOTICE file
distributed with this work for additional information
regarding copyright ownership. The ASF licenses this file
to you under the Apache License, Version 2.0 (the
"License"); you may not use this file except in compliance
with the License. You may obtain a copy of the License at


http://www.apache.org/licenses/LICENSE-2.0

Unless required by applicable law or agreed to in writing, software
distributed under the License is distributed on an "AS IS" BASIS,
WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
See the License for the specific language governing permissions and
limitations under the License.
-->
<workflow-app xmlns="uri:oozie:workflow:0.2" name="workflow IvanaSanchez">
  <start to="action_IvanaSanchez"/>
  <action name="action_IvanaSanchez">
    <map-reduce>
      <job-tracker>${jobTracker}</job-tracker>
      <name-node>${nameNode}</name-node>
      <prepare>
        <delete path="${nameNode}/user/${wf:user()}/${examplesRoot}/output-data/${$}
      </prepare>
    </configuration>

[ Read 61 lines ]
^G Get Help      ^O WriteOut
^X Exit          ^J Justify
^R Read File     ^Y Prev Page
^W Where Is     ^V Next Page
^K Cut Text      ^C Cur Pos
^U UnCut Text    ^T To Spell
```

Una vez editado, el archivo se subió a HDFS para que Oozie pudiera procesarlo:

```
hdfs dfs -put -f /home/cloudera/workspace/examples/apps/map-  
reduce/workflow.xml /user/cloudera/examples_oozie/apps/map-reduce/
```




```
cloudera@quickstart:~/workspace  
File Edit View Search Terminal Help  
[cloudera@quickstart workspace]$ hdfs dfs -put -f /home/cloudera/workspace/examp  
les/apps/map-reduce/workflow.xml /user/cloudera/examples_oozie/apps/map-reduce/  
[cloudera@quickstart workspace]$ clear
```

3. Configuración y Ejecución del Job

La ejecución de un job en Oozie requiere la coordinación entre un archivo local de propiedades y la lógica almacenada en HDFS.

Ajuste de job.properties (Resolución de error E0504)

Durante el proceso, se corrigió el parámetro `oozie.wf.application.path` para que apuntara a la ruta exacta del despliegue en HDFS (`/user/cloudera/examples_oozie/apps/map-reduce/`), evitando así errores de directorio inexistente.




```
cloudera@quickstart:~/workspace  
File Edit View Search Terminal Help  
GNU nano 2.0.9 File: ...era/workspace/examples/apps/map-reduce/job.properties  
  
# Licensed to the Apache Software Foundation (ASF) under one  
# or more contributor license agreements. See the NOTICE file  
# distributed with this work for additional information  
# regarding copyright ownership. The ASF licenses this file  
# to you under the Apache License, Version 2.0 (the  
# "License"); you may not use this file except in compliance  
# with the License. You may obtain a copy of the License at  
#  
# http://www.apache.org/licenses/LICENSE-2.0  
#  
# Unless required by applicable law or agreed to in writing, software  
# distributed under the License is distributed on an "AS IS" BASIS,  
# WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.  
# See the license for the specific language governing permissions and  
# limitations under the License.  
#  
nameNode=hdfs://localhost:8020  
jobTracker=localhost:8021  
queueName=default  
examplesRoot=examples  
  
oozie.wf.application.path=hdfs://localhost:8020/user/cloudera/examples_oozie/apps/map-red$  
outputDir=map-reduce  
  
[ Read 25 lines ]  
^G Get Help ^O WriteOut ^R Read File ^Y Prev Page ^K Cut Text ^C Cur Pos  
^X Exit ^J Justify ^W Where Is ^V Next Page ^U UnCut Text ^T To Spell
```

Lanzamiento del Job

Se ejecutó el comando de ejecución vinculando el motor de Oozie con el archivo de propiedades local:

```
oozie job -oozie http://localhost:11000/oozie -config examples/apps/map-reduce/job.properties -run
```

El sistema confirmó la recepción del flujo devolviendo un Job ID único terminado en -W (Workflow).




```
cloudera@quickstart:~/workspace
File Edit View Search Terminal Help
[cloudera@quickstart workspace]$ oozie job -oozie http://localhost:11000/oozie -
config /home/cloudera/workspace/examples/apps/map-reduce/job.properties -run
job: 00000000-260430094101133-oozie-oozi-W
[cloudera@quickstart workspace]$
```

4. Monitorización y Verificación de Resultados

La monitorización se realizó mediante dos vías, validando que la personalización de nombres fue exitosa:

- **Vía Terminal:** Mediante el comando -info, se verificó que el estado del job fuera RUNNING y que el nombre del workflow coincidiera con el asignado (workflow_IvanaSanchez).



```
cloudera@quickstart:~/workspace
File Edit View Search Terminal Help
[cloudera@quickstart workspace]$ oozie job -oozie http://localhost:11000/oozie -
info 00000000-260430094101133-oozie-oozi-W
Job ID : 00000000-260430094101133-oozie-oozi-W
-----
Workflow Name : workflow_IvanaSanchez
App Path      : hdfs://localhost:8020/user/cloudera/examples_oozie/apps/map-redu
ce
Status        : RUNNING
Run           : 0
User          : cloudera
Group         : -
Created       : 2026-05-01 21:33 GMT
Started       : 2026-05-01 21:33 GMT
Last Modified  : 2026-05-01 21:33 GMT
Ended         : -
CoordAction ID: -
Actions
-----
ID          Ext ID          Ext Status Err Code          St
atus
-----
00000000-260430094101133-oozie-oozi-W@action_IvanaSanchez          PR
EP          -          -          -
-----
00000000-260430094101133-oozie-oozi-W@:start:          OK
-          -          -          -
-----
Nuevo Documento de texto.txt (sf_datos) - aedit
```

- **Consola Web (Oozie Web Console):** Se utilizó la interfaz gráfica para visualizar el DAG (Grafo Acíclico Dirigido). En el esquema visual, se confirmó que el nodo de ejecución (action) mostraba correctamente la etiqueta personalizada action_IvanaSanchez.

The first screenshot shows the Oozie Web Console interface. The 'All Jobs' tab is selected, and a table of jobs is displayed. One job is highlighted with a red box:

Job Id	Name	Status	Run	User	Group	Created	Started	Last Modified
0000000-260430094101133-oozie-oozi-W	workflow_Ivana...	RUNNING	0	cloudera		Fri, 01 May 2026 21:33:31 GMT	Fri, 01 May 2026 21:33:31 GMT	Fri, 01 May 2026 21:33:31 GMT

The second screenshot shows the details of the selected job. The 'Job Info' tab is selected, and the job's configuration is displayed. Below the configuration, the 'Actions' tab is selected, showing a table of actions:

Action Id	Name	Type	Status	Transition	StartTime	EndTime
0000000-260430094101133-oozie-oozi-W@action_Ivana...	action_Ivana...	map-reduce	PREP			
0000000-260430094101133-oozie-oozi-W@:start:	:start:	:START:	OK	action_Ivana...	Fri, 01 May 2026 21:33:31 GMT	Fri, 01 May 2026 21:33:31 GMT

5. Conclusiones y Aprendizaje

- **Automatización:** hemos podido comprender cómo Oozie elimina la necesidad de intervención manual al encadenar procesos complejos en Hadoop.
- **Arquitectura de Configuración:** Se validó la importancia de separar la lógica (XML en HDFS) de los parámetros de ejecución (Properties en Local).
- **Gestión de Errores:** Se identificaron y resolvieron fallos comunes de rutas (E0504) y sintaxis XML (E0701), fundamentales para la administración de entornos Big Data.