

PROCESAMIENTO DE TEXTO CON “NLTK”

INTRODUCCIÓN

En la presente actividad se ha aplicado un conjunto de técnicas básicas de Procesamiento de Lenguaje Natural (NLP) sobre un texto literario proporcionado en formato .txt, sin información previa acerca de su autor o título. El objetivo principal ha sido transformar un texto en bruto en un conjunto estructurado de métricas cuantitativas y lingüísticas que permitan extraer información relevante sobre su contenido, estructura y características narrativas.

Para ello, se ha desarrollado un script en Python utilizando principalmente la librería NLTK, mediante el cual se han realizado procesos de tokenización, normalización, eliminación de stopwords, análisis de frecuencias léxicas, generación de n-gramas, stemming y aproximación morfológica para la identificación de verbos y adjetivos. Asimismo, se ha llevado a cabo un análisis estadístico de signos de puntuación, números, uso de mayúsculas y segmentación en frases.

A partir de los resultados obtenidos, se ha realizado una deducción fundamentada sobre la identidad de la obra, su autor, género, estructura interna y temática principal, demostrando cómo el análisis automatizado del lenguaje puede proporcionar información contextual significativa sin necesidad de consultar directamente la fuente original.

INFORME DE RESULTADOS

Identificación de la obra

A partir del análisis estadístico y morfológico del texto, se puede deducir con bastante seguridad que la obra analizada es:

Fuenteovejuna

Autor: Lope de Vega

Justificación basada en los datos obtenidos

```
C:\Users\Ivana\Desktop\3.1-Procesamiento_texto_Ivana_Sánchez\python procesamiento_texto.py
[ nltk_data ] Downloading package punkt to
[ nltk_data ] C:\Users\Ivana\AppData\Local\Temp\nltk_data...
[ nltk_data ] Package punkt is already up-to-date!
[ nltk_data ] Downloading package punkt_tab to
[ nltk_data ] C:\Users\Ivana\AppData\Local\Temp\nltk_data...
[ nltk_data ] Package punkt_tab is already up-to-date!
[ nltk_data ] Downloading package stopwords to
[ nltk_data ] C:\Users\Ivana\AppData\Local\Temp\nltk_data...
[ nltk_data ] Package stopwords is already up-to-date!

ARCHIVO textual.txt CARGADO

===== RESULTADOS =====

Idioma detectado: es
Total palabras: 14977
Total palabras únicas: 7129

Stopwords:
Total: 2814
Top 2: [('que', 616), ('de', 428), ('y', 395)]

Mayúsculas eliminadas: 1822
Top 3 mayúsculas: [('COMENDADOR', 127), ('LAURENCIA', 119), ('FRONDOSO', 92)]

Signos de puntuación: 3516
Signos de exclamación: 1580

Número encontrado: 184
Número más grande: 164

Top 20 palabras más frecuentes:
[('comendador', 153), ('laurencia', 141), ('frondoso', 115), ('mengo', 104), ('esteban', 87), ('si', 87), ('pues', 80), ('bien', 68), ('flores', 59), ('pascuala', 58), ('señor', 55), ('barrildo', 52), ('tan', 48), ('maestre', 43), ('re', 38), ('fuenteovejuna', 36), ('regidor', 36), ('equi', 36), ('octavo', 35), ('ser', 33)]

Top 5 raíces más frecuentes:
[('comend', 153), ('laurenci', 141), ('frondos', 115), ('meng', 104), ('esteb', 87)]

Top 5 verbos (agras):
[('ser', 35), ('fernando', 23), ('dar', 19), ('día', 12), ('ver', 12)]

Top 4 adjetivos (agras):
[('frondoso', 115), ('real', 26), ('gente', 14), ('real', 13), ('tal', 13)]

Top 5 bigramas:
[('juan', 'rujo'), 28], (('fernán', 'gómez'), 18), (('ciudad', 'real'), 13), (('vansa', 'salen'), 10), (('laurencia', 'pascuala'), 9)]

Top 5 trigramas:
[ (('rodrigo', 'céllez', 'giron'), 4), (('comendador', 'flores', 'ortufo'), 4), (('fernán', 'gómez', 'guzmán'), 3), (('dos', 'regidores', 'ciudad'), 3), (('regidores', 'ciudad', 'real'), 3)]

Número de frases (NLTK): 1181
Número de frases (Manual): 1179

Nombres personajes detectados:
[('COMENDADOR', 127), ('LAURENCIA', 119), ('FRONDOSO', 92), ('MENGO', 87), ('ESTEBAN', 85), ('FLORES', 52), ('PASCUALA', 50), ('BARRILDO', 49), ('REGIDOR', 34), ('Y', 33)]

Páginas estimadas: 61.35

PDF "Resultados_obtenidos.pdf" generado correctamente
```

1. Frecuencia de nombres propios

Las palabras más frecuentes del texto son:

- comendador (153)
- laurencia (141)
- frondoso (115)
- mengo (104)
- esteban (87)

Además, las palabras completamente en mayúsculas más frecuentes son:

- COMENDADOR (127)
- LAURENCIA (119)
- FRONDOSO (92)

Esto es característico del teatro del Siglo de Oro, donde los personajes aparecen en mayúsculas antes de cada intervención.

El personaje del Comendador es clave en *Fuenteovejuna*, lo que refuerza claramente la deducción.

2. Bigramas y trigramas clave

Entre los más frecuentes aparecen:

- ("fernán", "gómez")
- ("fernán", "gómez", "guzmán")
- ("rodrigo", "téllez", "girón")
- ("ciudad", "real")

Estos nombres corresponden a personajes históricos y figuras directamente relacionadas con la obra:

- Fernán Gómez de Guzmán → el Comendador
- Rodrigo Téllez Girón → Maestre de Calatrava
- Ciudad Real → contexto histórico real de la obra

Esto confirma aún más la identificación.

Tipo de obra

La obra es:

- Género: Teatro
- Subgénero: Drama histórico del Siglo de Oro
- Movimiento literario: Barroco español

Se trata de una obra teatral en verso estructurada en actos.

Personajes principales detectados

Según el análisis de frecuencias:

- Comendador
- Laurencia
- Frondoso
- Mengo
- Esteban
- Pascuala
- Barrildo
- Flores

Ivana Sánchez Pérez

- Ortuño
- Regidores

Los datos coinciden con los personajes principales de *Fuenteovejuna*.

Número estimado de páginas

Tu script estima:

61,35 páginas

Considerando una media de 250–300 palabras por página, la estimación resulta coherente con una edición estándar de la obra, que suele oscilar entre 60 y 80 páginas dependiendo del formato.

Estimación muy razonable.

Tipo y número de divisiones

La obra está estructurada en:

- 3 actos

Esta división es típica del teatro del Siglo de Oro. Aunque el script no detecta explícitamente encabezados como “Acto I”, “Acto II” o “Acto III”, la estructura dialogada y la extensión del texto sugieren claramente esta organización.

Temática

A partir del análisis de frecuencias y personajes se deduce que la temática principal es:

- Abuso de poder
- Honor colectivo
- Rebelión popular
- Justicia frente a tiranía
- Unidad del pueblo

La elevada frecuencia del término “comendador” y la presencia recurrente del “rey” reflejan un conflicto de poder que articula el desarrollo narrativo de la obra.

Comparación de tokenización de frases

- NLTK: 1151 frases
- Método manual: 1179 frases

La diferencia se debe a que NLTK utiliza modelos estadísticos más precisos para detectar límites de oración, mientras que el método manual divide simplemente por signos de puntuación.

Por tanto, el método basado en NLTK resulta más fiable desde el punto de vista técnico.

CONCLUSIÓN FINAL

El análisis cuantitativo y morfológico del texto permite identificar con alta probabilidad la obra como *Fuenteovejuna* de Lope de Vega. La frecuencia dominante de nombres propios como Comendador, Laurencia y Frondoso, junto con bigramas y trigramas asociados a personajes históricos reales, confirman la deducción. La estructura dialogada en mayúsculas evidencia que se trata de una obra teatral, mientras que la estimación de páginas y el análisis temático refuerzan la coherencia con ediciones habituales del texto.

El procesamiento mediante técnicas de NLP ha permitido transformar un texto sin contexto en un conjunto de métricas suficientes para identificar autor, género, estructura y contenido narrativo, demostrando la utilidad del análisis automatizado en el estudio de obras literarias.