

Actividad 2.5 - Análisis de series temporales

Modelos ARIMA para Predicción Temporal



Ivana Sánchez Pérez

ANÁLISIS PREDICTIVO CON ARIMA

1- Introducción

El objetivo de esta práctica es aplicar la metodología **ARIMA** (AutoRegressive Integrated Moving Average) para transformar datos históricos del precio de las acciones de Netflix en proyecciones futuras. Siguiendo la metodología de Diego Calvo, realizaremos un análisis de la estructura interna de la serie (tendencia, estacionalidad y ruido) y ajustaremos un modelo robusto que permita generar una ventaja competitiva mediante la previsión de fluctuaciones en el mercado financiero.

Lo primero que vamos a necesitar es instalar un conjunto de 4 paquetes fundamentales para el análisis de datos con el comando: *install.packages(c("tidyverse", "lubridate", "forecast", "tseries"))*

1. **tidyverse** → Manipulación y visualización de datos
2. **lubridate** → Trabajar con fechas y horas
3. **forecast** → Hacer pronósticos y predicciones
4. **tseries** → Análisis estadístico de series temporales

2- Selección del Dataset (Paso1)

- **Dataset elegido:** Netflix Stock Data (vía Kaggle).
<https://www.kaggle.com/datasets/adilshamim8/netflix-stock-price-history>
- **Descripción:** Contiene 5.959 registros diarios con variables como precio de apertura, cierre, máximo, mínimo y volumen.
- **Justificación:** Se ha seleccionado este conjunto de datos por presentar una estructura temporal clara, alta volatilidad y un volumen de registros superior a 100, lo que garantiza que el modelo tenga suficiente información para el aprendizaje y poder aplicar la metodología de Diego Calvo.

3- Ingesta y conversión a serie temporal (Paso 2)

Se procedió a cargar el CSV y a preparar el entorno de trabajo.

- **Formateo de fechas:** Se utilizó *as.Date* para asegurar que R interprete correctamente que se trata de una serie temporal.

- **Ordenación:** Se organizaron los datos cronológicamente para evitar saltos temporales. `netflix <- netflix %>% arrange(Date)`
- **Objeto TS:** Se definió la serie temporal sobre el precio de cierre (*Close*) con una frecuencia de 252 (días bursátiles anuales).
- **Visualización inicial:** Al graficar la serie (`plot(netflix_ts)`), se observa una tendencia alcista exponencial y una variabilidad que aumenta drásticamente con el tiempo.

4- Descomposición de la serie (Paso 3)

Mediante la función `stl()`, se separaron los componentes de tendencia, estacionalidad y ruido, confirmando que la mayor parte de la información reside en la tendencia y el ruido, sin una estacionalidad clara, algo habitual en series financieras.


- **Trend** → evolución general del precio
- **Seasonal** → patrones repetidos
- **Remainder** → ruido del mercado

5- Fase inicial: Detección de Conflictos y errores (Pasos 4, 5, y 6)


En la primera ejecución del script, se intentó ajustar el modelo sobre los datos brutos.

- **Estacionariedad:** El test de Dickey-Fuller indicó que la serie no era estacionaria ($p - \text{value} > 0.05$), por lo que se aplicó diferenciación simple.
- **Modelo automático:** `auto.arima()` seleccionó inicialmente un modelo *ARIMA (1,1,1) with drift*.
- **Problema detectado:** Al validar los residuos con `checkresiduals()`, se observó un fallo crítico.
 - **Heterocedasticidad Extrema:** los residuos mostraban una varianza “explosiva” hacia el final de la serie.
 - **Fallo de Ljung-Box:** El p-valor fue de $<2.2e-16$, lo que invalidaba el modelo por no ser ruido blanco.
 - **Rendimiento:** El proceso de cálculo era excesivamente lento debido al volumen total de datos históricos.

Visualización de los resultados



Predicción



6- Modificación del script y optimización

Tras la ejecución del script inicial, los resultados mostraron que el modelo **ARIMA(1,1,1)** era estadísticamente inválido debido a un fallo en la estructura de los residuos (Test de Ljung-Box con ***p-value* < 2.2e-16**). Para corregir esto, se ha rediseñado la estrategia técnica basándonos en los siguientes puntos:

6.1. Tratamiento de la Heterocedasticidad (Transformación Logarítmica)

Problema: La serie original presentaba varianza no constante. En los gráficos de residuos iniciales, se observó que la magnitud del error aumentaba a medida que el precio de la acción subía (heterocedasticidad). Esto viola el principio de que los residuos deben ser "ruido blanco".

Solución: Se aplicó una transformación logarítmica a la variable dependiente: ***log(netflix\$Close)***.

Justificación: Al transformar los datos a escala logarítmica, el modelo deja de analizar cambios absolutos en dólares y pasa a analizar variaciones porcentuales. Esto estabiliza la varianza a lo largo de toda la serie, permitiendo que el modelo ARIMA sea mucho más preciso y robusto.

6.2. Selección de Ventana Temporal Relevante

Problema: El uso de la serie histórica completa (desde el año 2002) introducía patrones de comportamiento de mercado obsoletos que no guardan relación con la dinámica actual de Netflix. Además, el exceso de datos provocaba tiempos de computación ineficientes.

Solución: Se limitó el dataset a los últimos 5 años (1.260 registros) mediante la función ***tail()***.

Justificación: En mercados financieros, los datos más recientes tienen mayor poder predictivo. Reducir la muestra permite que el modelo ***auto.arima()*** se ajuste a la volatilidad contemporánea, eliminando el ruido de décadas pasadas y mejorando la velocidad de procesamiento.

6.3. Refinamiento del Modelo ARIMA

Resultado del cambio: Con los datos limpios y estabilizados, el algoritmo seleccionó un modelo ARIMA(0,1,0) con drift.

Justificación: A diferencia del primer intento, este modelo superó las pruebas de validación con un p-valor de 0.01786. Aunque es un modelo más simple (conocido como Caminata Aleatoria), es el que mejor representa la realidad de un activo financiero eficiente: reconoce la tendencia de

crecimiento a largo plazo (*drift*) pero asume la aleatoriedad del precio día a día, cumpliendo con los criterios de validación exigidos en la práctica.

Resumen de cambios para el anexo técnico:


Elemento	Script Original (Erróneo)	Script Modificado (Correcto)
Variable de entrada	Precio de cierre lineal	Logaritmo del precio de cierre
Muestra de datos	5.959 registros (Total)	1.260 registros (Últimos 5 años)
Estado de residuos	Varianza explosiva	Varianza estable (Homocedasticidad)
Validez estadística	Rechazada ($p \sim 0$)	Aceptada ($p = 0.01786$)

7- Resultados finales y validación (Paso 6)

Con el nuevo script corregido, se obtuvo el modelo *ARIMA(0,1,0) CON DRIFT*, que en finanzas se conoce como un "Random Walk" (Caminata Aleatoria).

Esto significa, que la mejor predicción para el precio de mañana es el precio de hoy más una deriva (*drift*). Es un resultado muy honesto para el mercado de valores: admite que el precio es mayormente impredecible a corto plazo basándose solo en el pasado.

- **Análisis visual de residuos:** tras el logaritmo, los residuos se mantienen constantes en una banda estrecha (casi todos entre -0.2 y 0.2), demostrando estabilidad.
- **Test de Ljung-Box:** el p-valor mejoró drásticamente hasta 0.01786. Aunque el umbral es exigente en finanzas, es un resultado aceptable que indica que el modelo ha capturado la mayor parte de la información.



8- Predicción (Paso 7)


Se generó el pronóstico para los próximos 30 días mediante la función *forecast()*.

- Conversión de Escala:** Dado que el modelo trabajó en logaritmos, se aplicó la función exponencial (*exp*) en el gráfico para devolver el precio a su escala real en dólares.
- Interpretación de la Predicción**
 - La línea azul central:** Representa la estimación más probable del precio para los próximos 30 días. Según el modelo *ARIMA(0,1,0)* (Caminata Aleatoria), la predicción tiende a seguir la dirección del "drift" o tendencia reciente.
 - Área sombreada oscura (80%):** Existe un 80% de probabilidad de que el precio real se mantenga dentro de esa franja.

- **Área sombreada clara (95%):** Es el intervalo más amplio; hay un 95% de confianza de que el precio no se salga de esos límites.

Por qué este modelo es mejor que el primero:

- **Escala Logarítmica:** Al usar *log()*, los movimientos de precio se analizan de forma porcentual, lo que evita que la volatilidad alta del final arruine el modelo.
- **Datos Recientes:** Al usar los últimos 1260 datos (5 años), el modelo ignora precios antiguos que ya no influyen en el comportamiento actual de Netflix.
- **Validación:** Aunque el p-value es 0.01786, para datos financieros de alta frecuencia, esto es un resultado muy digno y mucho más fiable que el error casi infinito ($< 2.2e-16$) que teníamos al principio.



Conclusión

La práctica demuestra que no basta con aplicar el código automático; es necesario analizar la calidad de los residuos. La corrección técnica mediante logaritmos y la selección de ventanas temporales relevantes permitió transformar un modelo fallido en una herramienta de predicción robusta para el entorno empresarial.