

Informe Técnico: Análisis de Componentes Principales (PCA)

1. Introducción

En el ámbito del Big Data, el Análisis de Componentes Principales (PCA) es una técnica fundamental para combatir la "maldición de la dimensionalidad". Este proceso permite transformar un conjunto de variables originales correlacionadas en un nuevo conjunto de variables independientes denominadas Componentes Principales. El objetivo es reducir el volumen de datos reteniendo la máxima varianza (información) posible, facilitando así la visualización y eliminando el ruido redundante.

2. Análisis del Dataset Principal: mtcars

2.1 Preparación e Inspección

Se ha utilizado el dataset nativo mtcars (datos de automóviles de 1974). La inspección inicial mediante `str()` y `head()` confirma un conjunto de 32 observaciones y 11 variables numéricas. Se verificó la **ausencia de valores nulos (NA)**, asegurando la integridad del análisis.

2.2 Análisis de Correlación

Antes de aplicar PCA, se generó una matriz de correlación para justificar la técnica.

- **Observación:** Se detectaron correlaciones extremadamente fuertes entre variables como cilindrada (`cyl`), desplazamiento (`disp`), caballos de potencia (`hp`) y peso (`wt`). Esta redundancia confirma que el PCA será altamente efectivo para simplificar el dataset.

2.3 Modelo PCA y Estandarización

Se aplicó la función `prcomp(mtcars, scale = TRUE)`. El escalado es crítico en este caso, ya que variables como el desplazamiento tienen magnitudes de cientos, mientras que otras como la relación del eje trasero (`drat`) tienen valores pequeños. Sin estandarizar, las variables de mayor escala dominarían erróneamente el análisis.

2.4 Selección de Componentes y Biplot

- **Criterio del Codo (Scree Plot):** El gráfico de sedimentación muestra un descenso brusco tras la segunda componente. La **PC1** explica aproximadamente el **60%** de la varianza y la **PC2** el **18%**. Juntas, capturan cerca del **80%** de la información total.
- **Interpretación del Biplot:** * **PC1 (Eje Horizontal):** Define la "potencia y tamaño". Coches como el *Maserati Bora* se sitúan a la derecha (altos en hp, cyl), mientras que el *Honda Civic* está a la izquierda (alto en mpg / eficiencia).
 - **PC2 (Eje Vertical):** Se asocia principalmente con la transmisión y carburación (gear, carb).

3. Ampliación: Dataset USArrests

Para profundizar en la técnica, se ha aplicado el modelo al dataset USArrests, que contiene tasas de criminalidad por cada 100,000 habitantes en 50 estados de EE.UU.

3.1 Justificación y Metodología

Este dataset presenta variables con escalas muy diversas (ej. Assault tiene una media de 170.8, mientras que Murder es de 7.8). El uso de `scale = TRUE` fue obligatorio para obtener resultados válidos.

3.2 Resultados de la Ampliación

- **Varianza Explicada:** En este caso, el Scree Plot indica que la primera componente es dominante, pero se requieren dos componentes para alcanzar una explicación acumulada del **86.7%**.
- **Interpretación del Biplot:**
 - **Agrupación de Crímenes:** Los vectores de Murder, Assault y Rape apuntan en una dirección similar, indicando que los estados con altos índices de un tipo de crimen suelen presentar altos índices en los demás.
 - **PC2 y Urbanización:** El vector UrbanPop es perpendicular a los de criminalidad en gran medida, lo que sugiere que el nivel de urbanización es una dimensión independiente de la tasa de asesinatos en este conjunto de datos.

- **Perfiles de Estados:** Estados como *Mississippi* y *Georgia* destacan por altos índices de criminalidad (bajos en PC1), mientras que estados como *Vermont* se sitúan en el extremo opuesto.

4. Conclusiones

La práctica demuestra que:

1. El PCA simplifica con éxito estructuras de datos complejas, permitiendo visualizaciones en 2D que resumen fielmente la realidad multidimensional.
2. El **Criterio del Codo** es una herramienta eficaz para no sobrecargar los modelos con componentes innecesarias.
3. La interpretación de los vectores en el **Biplot** permite identificar qué variables del "mundo real" están representadas en cada eje abstracto, convirtiendo datos brutos en conocimiento de negocio.